

數據科學實務與創新一期末報告

羅馬數字辨識數據分析研究

指導教授： 鍾思齊 教授

組員：M132040010 洪培升

M132040021 吳世惟

M132040024 馬嘉笛

摘要

在深度學習與機器學習領域，數據品質與數量對模型的表現至關重要。本研究採用 Clean Vision 套件進行數據清理，強調以全自動化的方式檢測並剔除標籤錯誤的圖片，避免人工干擾造成的偏差，並利用 Albumentation 套件進行增強，同時在清理與增強的基礎上，最大化訓練圖片數量以達到數據集規模的最佳化。此外，針對不同增強技術進行系統化測試與參數優化，提升圖像數據的多樣性與品質，增強模型對多樣化圖片的適應性與穩健性。

為了進一步提升數據品質，我們自主建構了三個模型，逐步解決數據標籤錯誤、大小寫分類不平衡，以及多類別診斷的挑戰：

- 一、模型 1：基礎羅馬數字診斷模型，專注於標籤錯誤檢測與高信心水準樣本分類，建立數據處理的基礎。
- 二、模型 2：大小寫信心水準修正模型，解決模型 1 之中，大小寫羅馬數分類不平衡問題，提升小寫樣本的分類準確率。
- 三、模型 3：整體羅馬數字診斷模型，整合前兩個模型的成果，實現羅馬數字 1 至 10 的統一分類。

透過這些策略，本研究在數據清理、增強與模型訓練方面達成了整體優化，為後續應用奠定了堅實基礎，並探索了多樣化數據優化的可行性與效果。

資料集介紹

本研究使用的資料集為羅馬數字手寫辨識數據，來源於 Kaggle 平台，內容涵蓋羅馬數字 I 至 X (1 至 10) 共 10 類手寫羅馬數字圖像。數據集分為訓練集 (train) 與驗證集 (val)，每個子目錄包含多張對應類別的手寫圖像，總計約 4,400 張圖片。本專案要求對圖像進行預處理並可選擇自定義的訓練與驗證集比例，但整體數據量不得超過 12,000 張。

研究目標

本研究旨在透過數據品質提升與多樣性優化，為手寫羅馬數字分類模型的訓練奠定堅實基礎，實現羅馬數字 I 至 X (1 至 10) 的高準確度分類。具體目標如下：

1. 數據清理

採用 Clean Vision 套件自動化檢測並剔除標籤錯誤及低品質圖像，確保訓練數據的準確性與一致性。

2. 數據增強

利用 Albumentation 套件進行多樣化增強，模擬不同書寫與成像條件，提升數據集的多樣性與模型泛化能力。

3. 類別平衡

解決小寫羅馬數字樣本數量不足的問題，優化分類模型，確保每類別的預測性能均衡。

4. 多模型整合

開發三個協同工作的模型，實現從標籤檢測、類別平衡到整體分類的全流程優化。

5. ResNet50 訓練與評估

基於 ResNet50 模型進行訓練，使用 Kaggle 測試集驗證性能，以 F1-score 作為主要評估指標，確保多類別任務中的均衡準確性。

資料前處理

一、核心理念

1. 禁止透過人工干擾手動刪除不適當資料

以自動化方式精準檢測並剔除標籤錯誤的圖片，避免主觀干擾造成數據偏差，確保訓練資料的品質與準確性。

2. 移除標籤錯誤圖片

精準檢測並剔除標籤錯誤的圖片，確保訓練資料的品質與準確性。

二、處理過程(利用 CleanVision 套件)

1. 處理 odd_aspect_ratio 問題 (Table_0 → Table_1)

作用：識別並處理比例異常的圖片，例如過於寬或過於高的圖片。

結果：成功移除 1 張比例異常的圖片。

2. 處理 near_duplicates 問題 (Table_1 → Table_2)

作用：識別並移除相似度過高的重複圖片，並自定義函數計算圖片的噪點程度，移除噪點較多的圖片。

結果：成功移除 44 張近似重複的圖片。

意外收穫：移除的 44 張圖片中，有 42 張是標籤錯誤。

3. 處理 grayscale 問題 (Table_2 → Table_3)

作用：自定義函數將彩色圖片轉換為灰階圖片，或者識別並處理灰階圖片。

結果：所有圖片皆轉為灰階。

4. 處理 light 問題 (Table_3 → Table_4)

作用：自定義函數調整圖片的亮度，使其符合統一的亮度標準。

結果：成功處理 1 張亮度異常的圖片，使得 near_duplicates 問題再次浮現。

5. 再一次處理 near_duplicates 問題 (Table_4 → Table_5)

作用：識別並移除相似度過高的重複圖片，並自定義函數計算圖片的噪點程度，移除噪點較多的圖片。


結果：成功移除 7 張近似重複的圖片。

意外收穫：移除的 7 張圖片中，全部皆是標籤錯誤。

6. 刪除全白或全黑的圖片 (Table_5 → Table_6)

作用：自定義函數刪除所有像素值都是 0 (全白) 或所有像素值都是 255 (全黑)，並剔除全白或全黑的圖片，以保持數據集的有效性和多樣性。

結果：成功移除 1 張全白的圖片。



上述步驟 1.至步驟 6.達到不錯的效果，在此階段移除的 near_duplicates 問題共 51 張，有 49 張是正確移除標記錯誤的圖片，有完整運行核心理念，接著只剩下 low_information 的問題尚須處理，嘗試以下步驟 7.至步驟 12.效果不佳，故最後未能採用：

7. 增強圖片的對比度 (Table_6 → Table_7)

作用：調整圖片的對比度，使圖像細節更清晰，增強圖片品質。

結果：成功增強了所有圖片的對比度，但對於 low_information 問題無顯著改善，並再次出現 near_duplicates 問題再次浮現。

8. 處理 near_duplicates 問題 (Table_7 → Table_8)

作用：識別並移除相似度過高的重複圖片，並自定義函數計算圖片的噪點程度，移除噪點較多的圖片。

結果：成功移除 2 張近似重複的圖片。

意外收穫：移除的 2 張圖片中，全部皆是標籤錯誤。

9. 裁剪圖片，並留下些微白邊 (Table_8 → Table_9)

作用：裁減圖片，僅保留含有白邊的部分，以確保圖片符合特定需求或標準。


結果：成功裁減了所有需要處理的圖片，並保留了白邊，但是 near_duplicates 問題激增，甚至出現上百張。

10. 再一次處理 near_duplicates 問題 (Table_9 → Table_10)

作用：識別並移除相似度過高的重複圖片，並自定義函數計算圖片的噪點程度，移除噪點較多的圖片。

結果：成功移除 351 張近似重複的圖片。

意外結果：移除的 351 張圖片中，多組判斷錯誤且數量過多。



11. 統一圖片尺寸 (Table_10 → Table_11)


作用：將所有圖片的尺寸统一到指定的標準大小，確保模型在訓練時能接收一致的輸入，避免因圖片尺寸不一致而導致模型表現下降。

結果：成功將所有圖片统一到 32x32 像素的標準尺寸，圖片的內容與細節可能丢失太多，導致後續資料增強效果不佳。

12. 刪除圖片 low_information (Table_11 → Table_12)


作用：篩選並移除訊息量過低的圖片，也就是幾乎沒有特徵的圖片，以減少訓練時無效數據的干擾，提升模型的學習效率。

結果：成功移除 561 張 low_information 圖片，但也有可能因為移除比例太高，導致後續資料增強效果不佳。



Table_6			Table_7			Table_8			Table_9			Table_10			Table_11			Table_12		
T6	issue_type	num	T7	issue_type	num	T8	issue_type	num	T9	issue_type	num	T10	issue_type	num	T11	issue_type	num	T12	issue_type	num
0	grayscale	3314	0	grayscale	3314	0	grayscale	3312	0	grayscale	3312	0	grayscale	2961	0	grayscale	2961	0	grayscale	2400
1	low_information	3299	1	low_information	3271	1	low_information	3269	1	low_information	3269	1	low_information	2919	1	low_information	1629	1	low_information	1063
2	light	1063	2	light	1063	2	light	1062	2	near_duplicates	661	2	light	193	2	light	26	2	light	3
3	odd_size	60	3	odd_size	60	3	odd_size	60	3	light	211	3	odd_size	10	3	blurry	0	3	blurry	0
4	blurry	0	4	blurry	0	4	blurry	0	4	odd_size	13	4	blurry	0	4	dark	0	4	dark	0
5	dark	0	5	blurry	0	5	dark	0	5	blurry	0	5	dark	0	5	odd_aspect_ratio	0	5	odd_aspect_ratio	0
6	odd_aspect_ratio	0	6	dark	0	6	odd_aspect_ratio	0	6	dark	0	6	odd_aspect_ratio	0	6	odd_size	0	6	odd_size	0
7	exact_duplicates	0	7	odd_aspect_ratio	0	7	exact_duplicates	0	7	odd_aspect_ratio	0	7	exact_duplicates	0	7	exact_duplicates	0	7	exact_duplicates	0
8	near_duplicates	0	8	near_duplicates	0	8	near_duplicates	0	8	exact_duplicates	0	8	near_duplicates	0	8	near_duplicates	0	8	near_duplicates	0

上述步驟 7.至步驟 12.效果不佳，於是我們發現 low_information 的圖片大多由為許多虛線或是接近亂點的圖片所構成，於是自定義函數，試著找到合適的閾值移除這些照片：



13. 篩選與刪除低訊息量圖片

作用：利用多種圖像特徵（如連通域數量、前景像素總數與小域數量）篩選並刪除低訊息量圖片（尤其是許多虛線或是接近亂點的圖片）。

結果：成功刪除了 111 張圖片低訊息量或噪點過高的圖片，數據集品質顯著提升，以確保留下的圖片對於數據的代表性。



▲經由步驟 13.所移除的圖片（前 20 張）

資料增強

一、核心思想

1. 最大化訓練圖片數量

在資料清理與增強的前提下，盡量滿足訓練圖片數量限制（最大 12,000 張），以提升模型泛化能力。

2. 優化圖像增強參數

系統化測試並調整增強參數（如旋轉角度、裁剪範圍等），逐一嘗試最佳配置，確保不同參數組合對模型性能的最佳影響。

二、處理過程(利用 Albumentation 套件)

1. 平移、縮放與旋轉 (ShiftScaleRotate)

作用：對圖片進行平移、縮放及旋轉操作，模擬圖片在不同角度與比例下的變化，增加數據多樣性並提升模型對圖片位置與尺度變化的適應能力。

參數設置：

平移 `shift_limit = 0.20`：圖片隨機水平或垂直移動範圍，範圍在 20% 內。

縮放 `scale_limit = 0.20`：圖片隨機縮放比例範圍，範圍在 20% 內。

旋轉 `rotate_limit = 5`：圖片隨機旋轉角度範圍，範圍在 5° 內。

2. 隨機亮度與對比度調整 (RandomBrightnessContrast)

作用：調整圖片的亮度與對比度，用於模擬不同光照條件，提升模型在光線變化環境下的穩健性。

參數設置：

亮度 `brightness_limit = 0.20`：亮度調整範圍，範圍在 20% 內。

對比度 `contrast_limit = 0.20`：對比度調整範圍，範圍在 20% 內。

3. 添加高斯噪點 (GaussNoise)

作用：在圖片中添加高斯噪點，用於模擬不同程度的圖片噪點，提升模型在處理低質量或帶有干擾數據時的穩健性。

參數設置：

方差 `var_limit = (30.0, 70.0)`：噪點的方差範圍，設置為 30 ~ 70 之間。

平均 `mean = 0`：噪點均值，設置為 0。

4. 隨機裁剪與調整尺寸 (RandomResizedCrop)

作用：隨機裁剪圖片的一部分並調整到指定尺寸，用於模擬不同構圖與視角的圖片，提升模型對局部訊息的學習能力。

參數設置：

高度 `height = 64`：裁剪後的圖片高度，設置為 64。

寬度 `width = 64`：裁剪後的圖片寬度，設置為 64。

比例 `scale = (0.8, 1.0)`：裁剪區域佔原始圖像的比例範圍，設置為 0.8 ~ 1.0。

寬高比 `ratio = (0.75, 1.33)`：裁剪區域的寬高比範圍，設置為 3:4 到 4:3 之間。

三、運行結果

透過應用多種圖像增強技術及反覆調整參數設置，我們成功將原有的 3203 張圖片擴增至 11992 張，達到模型訓練的數據上限。這些增強技術不僅有效擴大了訓練數據集的規模，還顯著提升了模型對多樣化場景的穩健性與適應能力，最終，本研究為後續的模型訓練與性能優化奠定了堅實的數據基礎，並展現了圖像增強技術在提升模型表現上的實用性與價值。

構想模型

一、模型 1：建立個別羅馬數字診斷 CNN 模型

1. 目標

建立高準確率的個別羅馬數字診斷模型，針對標籤進行自動化檢測與標記，提升資料集品質並為後續研究提供基礎。

2. 研究假設

資料集中僅有少數標籤錯誤。

3. 研究目的

- 針對單一羅馬數字（如 I、II、III 等）建立專屬 CNN 模型。
- 使用該模型輸出「信心水準」的機率值，評估樣本是否符合正確標籤，從而檢測標籤錯誤。

4. 研究方法

(1) 資料準備

分類目標與負樣本：

- 分類目標類別與最不相似的負樣本類別，進行正負樣本建構。
- 將目標類別（如 I）與其最不相似的類別（如 X）作為正負樣本來源。
(I, X) (II, X) (III, X) (IV, X) (IX, V) (V, IX) (VI, X) (VII, X) (VIII, X) (X, VIII)
- 預處理資料：灰階轉換、雜訊去除、圖片大小統一。

資料清理：

將圖像轉換為灰階，以統一處理並簡化模型學習。去除資料中的雜訊，統一圖片大小（64x64）。

(2) CNN 模型設計

模型結構：

- 使用三層卷積層進行特徵提取，每層包含卷積、批次正規化與池化層。
- 平坦化輸出並加入全連接層進行特徵映射，最終使用 sigmoid 輸出二分類機率。

訓練配置：

- 使用 binary_crossentropy 作為損失函數。
- 使用 Adam 優化器，學習率設定為 0.001。
- 訓練輪數（epochs）設定為 5，批次大小（batch_size）為 32。

(3) 資料分析與信心水準排序

資料筆數與分布分析：

- 計算每個類別的總資料筆數，並檢查分布是否均衡。
- 繪製各類別 Confidence 欄位的直方圖，視覺化信心水準分布趨勢。

信心水準排序與分級：

- 將每個類別的資料按 Confidence 由高至低排序。
- 根據分位數將資料分為 5 個等級（Rank 1 至 Rank 5）：
Rank 1：信心水準位於前 20%。
Rank 2：信心水準介於 20%~50%。
Rank 3：信心水準介於 50%~60%。
Rank 4：信心水準介於 60%~90%。
Rank 5：信心水準位於後 10%，不列入後續生成與探討。

(4) 資料增強

信心水準生成權重：

根據資料的信心水準（Rank 1 至 Rank 4），分配不同的生成權重：

- Rank 1：賦予最高權重，生成更多增強樣本。
- Rank 2：賦予次高權重，平衡生成數量。
- Rank 3：賦予中等權重，保持合理增強比例。
- Rank 4：賦予最低權重，減少增強次數。

Albumentations 增強策略：

依據權重配置，對不同 Rank 的資料執行增強，並針對不同 Rank 資料，應用以下增強技術：

- 隨機旋轉、平移與縮放：模擬不同角度和位置變化，提高模型對變化的適應性。
- 光照調整與顏色抖動：模擬不同光照條件和顏色變化，增強模型對不同光線和顏色條件的穩健性。
- 隨機裁剪與填充：模擬不同裁剪和填充情況，提高模型對不同大小和比例的圖片的處理能力。

(5) 模型保存與結果

模型保存：將每個類別的 CNN 模型保存為.h5 檔案。


輸出信心水準與分級：


匯出每張圖片的信心水準與分級資料，用於資料品質優化或標籤錯誤檢測。

5. 核心成果

- 為每個羅馬數字建立專屬 CNN 模型，提升診斷準確率。
- 利用信心水準分級，自動檢測標籤錯誤並優化資料集品質。
- 排除 Rank 5 後 10% 資料，專注於 Rank 1 至 Rank 4 的樣本探討與增強。
- 提供統一化的高品質數據輸出，支援後續模型訓練與應用研究。

6. 模型輸出與結果分析

Rank 1 (高信心水準)		Rank 5 (低信心水準)	
id	Confidence	id	Confidence
 i_66.png	0.9963741	 i_60.png	0.035407342
 i_91.png	0.99227244	 i_87.png	0.11510588
 i_83.png	0.9855047	 i_32.png	0.19315463



上述結果顯示：

羅馬數字 I 經模型訓練後，輸出信心水準的高低排序資料。從低信心水準部分提取的前三筆資料中，可觀察到三張圖片中有兩張標籤錯誤，另有一張圖片因使用小寫字母而導致信心水準偏低。針對此問題，模型 2 將專注於解決小寫字母的低信心水準問題，進一步提升資料標籤準確性。整體來看，模型在偵測「錯誤標籤」問題上已展現一定成效。

二、模型 2：模型大寫判讀正確性

1. 研究背景與目的

模型 1 雖已能判斷羅馬數字正確性，但因資料集中大部分為大寫「I」，導致小寫「i」的信心水準偏低，進而影響標籤的準確性與分類公平性。因此，模型 2 旨在彌補大小寫信心水準落差，通過 CNN 訓練模型，獲取更公正的大小寫標籤分類。

2. 研究假設

模型 1 訓練結果正確品質過關。

3. 研究方法

(1) 數據準備

正樣本：

挑選 50 張分類正確的小寫「i」圖片，並使用與模型 1 相同的資料增強策略（如旋轉、平移、縮放等）擴增至 150 張，作為小寫「i」的正樣本特徵分布。

負樣本：

使用模型 1 的原始資料集（未增強，且捨去 Rank 5 的資料）作為負樣本，保留大寫「I」的真實分布特徵。

樣本權重調整：

為正樣本賦予較高的生成權重，以平衡正負樣本比例的差異，確保模型公平學習小寫「i」的特徵。

(2) CNN 模型設計

繼承模型 1 的結構，保持三層卷積層進行特徵提取，最終輸出兩個機率值：

CLASS_BIG（大寫類別機率）與 CLASS_SMALL（小寫類別機率）。

(3) 判讀與分類策略

CLASS_BIG 與 CLASS_SMALL 機率判讀：

- 對每筆資料同時計算 CLASS_BIG 與 CLASS_SMALL 的機率，生成報表。
- 判讀條件：i. 若兩者其中之一機率 < 70%，則刪除該筆資料。
ii. 根據機率值較高者判定為大寫或小寫類別。

資料比例調整：

合併大小寫資料時，將大寫與小寫的比例控制在 3:2，以確保模型不因學習小寫特徵而影響大寫準確性。

4. 數據處理與輸出

- **數據輸出：**

ID 識別碼；CLASS_BIG 機率：大寫機率；CLASS_SMALL 機率：小寫機率。

- **最終數據集：**

根據判讀結果清理無效資料，合併大小寫樣本至統一資料集中，比例控制為 3:2，確保數據分布平衡。

5. 核心成果

- 建立針對大小寫信心水準修正的專屬 CNN 模型。
- 彌補模型 1 中因大寫「I」過多導致的分類不公問題，提升小寫「i」的信心水準。
- 通過信心水準與權重調整，實現大小寫特徵的公平學習。
- 優化後的資料集，兼具大寫與小寫特徵分布的平衡性與代表性，為後續分類模型奠定基礎。

三、模型 3：建立整體羅馬數字診斷模型

1. 核心目標

- 整合模型 1 與模型 2 的成果，建構一個能診斷所有羅馬數字 1~10 的 CNN 模型，剔除錯誤分類的樣本，以提升分類準確性。
- 模型輸入圖像數據（可能含大小寫混雜情境），輸出對應的羅馬數字 1~10 的機率分布。

2. 研究方法

(1) 數據準備（結合模型 1 與模型 2 的數據）

大寫數據來源：使用模型 1 的 Rank 1 至 Rank 4 的數據作為主要大寫數據。

小寫數據來源：

使用模型 2 生成的小寫數據（增強後的 150 張小寫正樣本及權重調整數據）。

負樣本平衡：

加入非目標類型數據（例如其他類別的混淆字母圖像）作為訓練時的輔助樣本，減少過擬合。

(2) 模型訓練

損失函數與訓練配置：

損失函數：使用 categorical_crossentropy；優化器：Adam（學習率設為 0.001）。

訓練參數：

批次大小：32；訓練輪數（epochs）：15；使用早停策略（Early Stopping），當驗證損失連續 10 輪未降低時提前停止。

(3) 模型輸出

- 模型輸出為對應目標類別與所有類別的機率。
- 將每個輸入圖像分類為最大機率對應的羅馬數字。

(4) 性能評估

訓練集與測試集的準確率：評估整體羅馬數字分類任務上的準確率。

混淆矩陣：分析模型在不同羅馬數字類別上的表現。

(5) 模型保存

- 將最終模型保存為.h5 檔案。
- 保存大小寫平衡數據輸出的標籤及機率報表（格式包含 ID、CLASS、機率分布等資訊）。

(6) **數據清理與增強策略：**

刪除最大機率對應錯誤的數據：

在訓練初期，根據預測結果，將輸出最大機率對應的分類錯誤數據（誤分類樣本）刪除，並更新數據集。

Albumentations 增強策略（針對刪除分類錯誤數據後的數據進行增強）：

使用與模型 1 相同的資料增強策略（如隨機旋轉、平移、縮放等）。

模型比較

作法	分數
未做任何處理直接跑模型	0.61634
構想模型(Model_1)	0.68864
使用 CleanVision 移除部分錯誤圖片並進行資料增強	0.73041
使用 CleanVision 移除部分錯誤圖片與虛假標籤，並進行資料增強（最終版本）	0.76967

透過上述的不同作法，我們最終選擇了使用 CleanVision 移除部分錯誤圖片與虛假標籤，並進行資料增強（最終版本），該方法在模型評估中取得了最高的分數 0.76967，相較於未處理的原始資料（0.61634）明顯提升。

建議與改進

1. 標籤分類

- 精確進行正負樣本的建構，確保樣本之間不發生重疊或誤分類的情況。
- 探索更多負樣本組合策略，提升模型對異常標籤的識別能力。

2. 圖形增強

- 測試多種增強參數的組合（如旋轉角度、裁剪範圍等），以優化模型學習效果。
- 使用 Grid Search 或 Random Search 方法自動化優化增強配置，提升效率與效果。
- 根據不同類別的特徵，進行客製化的圖形增強調整，以滿足每個數字的專屬需求。

3. 遺珠之憾

由於算力限制（每個 EPOCH 至少需 30 分鐘），本次的構想模型（模型 1 至模型 3）無法完全實現，僅實現了部分測試。此構想需為每個數字單獨建立模型，總計需訓練以下模型數量。

- 模型 1：10 個模型（每個數字一個模型）
- 模型 2：同樣需建立 10 個模型
- 模型 3：僅需 1 個模型

合計共需訓練 21 個模型，對算力需求較高。初始設定訓練 50 次，但由於算力限制，僅能進行 5 次訓練，導致模型無法收斂，因此效果不夠準確。未來若資源允許，將進一步完成此構想，以驗證模型的全面性與實用性。

組內工作分配比例

	洪培升	馬嘉笛	吳世惟
程式編寫	30%	40%	30%
書面報告 簡報設計	30%	40%	30%
口頭報告	40%	20%	40%
總佔比	33.3%	33.3%	33.3%